

Detecção de Incêndios Florestais utilizando Modelos de Deep Learning

1st Luiz Benedito Alves Neto

Universidade Federal de Viçosa

Rio Paranaíba, Minas-Gerais

Email: luiz.b.neto@ufv.br

2nd Mariana de Deus Castro

Universidade Federal de Viçosa

Carmo do Paranaíba, Minas-Gerais

Email: mariana.d.castro@ufv.br

Abstract—Wildfires are one of the most pressing environmental threats, causing widespread damage to ecosystems, human safety, and global environmental stability. This study explores the use of deep learning models, specifically ResNet18, ResNet50, and EfficientNet, to develop a reliable and automated system for wildfire detection. Leveraging the Forest Fire BigData dataset, the models were trained using advanced data augmentation techniques to improve robustness and generalization. A comprehensive evaluation was conducted using metrics such as precision, recall, F1-score, and support, ensuring a detailed performance assessment. The findings highlight the effectiveness of deep learning in addressing challenges associated with traditional detection methods, offering a scalable and efficient solution for monitoring and mitigating wildfires. Future research will focus on enhancing datasets, integrating temporal data, and exploring hybrid models to further improve predictive capabilities and response strategies.

Index Terms—Deep learning, ResNet, EfficientNet, Data augmentation

I. INTRODUÇÃO

Os incêndios florestais são uma das catástrofes naturais mais devastadoras, causando danos irreparáveis ao meio ambiente, à biodiversidade e às economias locais. Globalmente, estima-se que ocorram mais de 220.000 incêndios florestais por ano, resultando na destruição de milhões de hectares de florestas e contribuindo significativamente para as emissões de gases de efeito estufa [1]. Esses eventos não apenas ameaçam habitats naturais, mas também colocam em risco vidas humanas e infraestrutura crítica, tornando sua detecção e mitigação uma prioridade global.

Métodos tradicionais de detecção de incêndios florestais, como vigilância manual, torres de observação e imagens de satélite convencionais, apresentam limitações importantes. Esses métodos frequentemente enfrentam desafios relacionados ao tempo de resposta, à precisão na identificação de focos de incêndio e à incapacidade de operar em escalas maiores com dados heterogêneos. Com o avanço das mudanças climáticas e o aumento da frequência dos incêndios, é evidente a necessidade de soluções tecnológicas mais robustas.

Nos últimos anos, o aprendizado profundo (Deep Learning), uma subárea da inteligência artificial (IA), emergiu como uma abordagem revolucionária para superar esses desafios. Por meio de redes neurais convolucionais (CNNs) e outras arquiteturas avançadas, técnicas de aprendizado profundo têm demonstrado uma capacidade excepcional de identificar

padrões complexos em grandes volumes de dados, como imagens de satélite, vídeos capturados por UAVs (veículos aéreos não tripulados) e dados de sensores remotos. Essas abordagens permitem detectar características sutis, como fumaça em estágios iniciais ou mudanças na vegetação causadas por calor extremo, com maior precisão e rapidez [2], [3].

Por exemplo, pesquisas recentes destacaram o uso de UAVs equipados com câmeras de alta resolução e modelos de aprendizado profundo para monitorar regiões propensas a incêndios. Essas tecnologias demonstraram alta eficácia na segmentação de imagens e identificação de focos de calor em tempo real [4]. Além disso, o uso de imagens de satélite combinadas com modelos de aprendizado profundo permitiu mapear áreas de risco e detectar incêndios em escalas globais, melhorando significativamente os tempos de resposta [5]. Outras inovações, como o uso de redes neurais recorrentes (RNNs) para análise de sequências temporais, também têm sido exploradas para prever a propagação de incêndios, contribuindo para estratégias preventivas mais eficazes [6].

No entanto, apesar de seu potencial, a aplicação de deep learning na detecção de incêndios florestais ainda enfrenta desafios. Questões como a disponibilidade e a qualidade dos dados, o custo computacional elevado e a necessidade de treinar modelos para cenários específicos continuam sendo barreiras importantes para sua ampla utilização.

Este artigo explora o uso de técnicas de deep learning na identificação de incêndios florestais. Discutiremos os avanços recentes na tecnologia, os desafios associados à sua aplicação prática e as perspectivas futuras para melhorar a detecção e a mitigação de incêndios florestais. Ao destacar os benefícios e limitações dessas abordagens, buscamos oferecer uma visão do papel do deep learning na gestão de desastres naturais.

II. REVISÃO BIBLIOGRÁFICA

A detecção de incêndios florestais por meio de aprendizado profundo (Deep Learning) tem evoluído rapidamente nos últimos anos, com avanços significativos no uso de modelos pré-treinados para melhorar a precisão e a eficiência desses sistemas. Esses modelos permitem que pesquisadores utilizem redes já otimizadas para tarefas gerais, adaptando-as para detecção de incêndios em contextos específicos.

Gupta e Mishra [7] exploraram o uso do MobileNetV2, um modelo pré-treinado leve, para detecção de incêndios em

florestas indianas, utilizando transferência de aprendizado para alcançar alta precisão em conjuntos de dados regionais. Essa abordagem demonstrou como modelos pré-treinados podem superar limitações associadas à escassez de dados locais de treinamento.

Hong et al. [8] conduziram uma análise comparativa de oito modelos pré-treinados, como ResNet e EfficientNet, aplicados à detecção de incêndios em imagens capturadas por câmeras convencionais. O uso da transferência de aprendizado permitiu adaptar esses modelos para tarefas de detecção de incêndios, mesmo em cenários com recursos computacionais limitados.

Outro trabalho relevante é o de Ahmad et al. [9], que propuseram o FireXNet, um modelo de IA explicável baseado em transferência de aprendizado para dispositivos de baixa capacidade computacional. O FireXNet utilizou modelos como VGG16 para detectar incêndios de forma eficiente, otimizando o uso de recursos em áreas remotas.

Partheepan e Sanati [10] compararam o desempenho de modelos customizados e pré-treinados, incluindo CNNs adaptadas, para detecção de incêndios em imagens aéreas. Sua pesquisa destacou as vantagens de modelos pré-treinados na redução do tempo de treinamento e na melhoria da precisão em cenários complexos.

Além disso, Ghali e Akhloufi [11] investigaram o uso de técnicas de transferência de aprendizado combinadas com UAVs para detectar incêndios em larga escala. Eles demonstraram como modelos pré-treinados, como MobileNet e Inception, podem ser reutilizados em cenários de sensoriamento remoto, oferecendo resultados superiores na detecção de fumaça e chamas.

Esses estudos evidenciam o papel crucial da transferência de aprendizado e dos modelos pré-treinados na detecção de incêndios florestais, especialmente em contextos onde dados de treinamento específicos são limitados. Apesar dos avanços, desafios como a personalização dos modelos para diferentes regiões e a eficiência em dispositivos de baixa potência continuam a impulsionar novas pesquisas no campo.

III. MATERIAIS E MÉTODOS

Este estudo utiliza três modelos pré-treinados amplamente reconhecidos no campo do aprendizado profundo: ResNet18, ResNet50 e EfficientNet. Esses modelos foram selecionados devido à sua eficácia em tarefas de classificação de imagens e à capacidade de generalizar para novos domínios, como a detecção de incêndios florestais.

A. Modelos Pré-Treinados

As Redes Neurais Residuais (ResNet), introduzidas por He et al. [12], abordam o problema da degradação em redes profundas, onde o desempenho tende a se estabilizar ou degradar à medida que a profundidade da rede aumenta. Por meio da introdução de conexões residuais ("shortcuts"), a ResNet permite a passagem direta de informações entre camadas, facilitando o aprendizado de funções complexas.

- **ResNet18:** Uma arquitetura de 18 camadas projetada para tarefas que exigem processamento rápido e eficiente, sendo ideal para cenários onde os recursos computacionais são limitados. Apesar de sua simplicidade, a ResNet18 é capaz de capturar características visuais fundamentais em imagens de incêndios florestais.

- **ResNet50:** Uma versão mais profunda com 50 camadas, que aumenta significativamente a capacidade de aprendizado. Essa profundidade adicional permite que o modelo extraia padrões mais sutis em imagens de alta resolução, como a presença de fumaça ou mudanças na vegetação.

Ambos os modelos foram pré-treinados no conjunto de dados ImageNet, que contém milhões de imagens em milhares de categorias, e são amplamente utilizados como base para tarefas de transferência de aprendizado.

Já o **EfficientNet**, introduzido por Tan e Le [13], representa uma inovação em eficiência computacional, combinando escalabilidade com alta precisão. Ele emprega uma abordagem chamada compound scaling, que ajusta de forma balanceada a profundidade, largura e resolução de entrada do modelo, otimizando o uso de recursos computacionais.

B. Dataset

O conjunto de dados utilizado neste estudo é o Forest Fire BigData, disponível publicamente no Kaggle [14]. Este dataset contém um total de 1.832 imagens, divididas em duas classes principais:

- Com Incêndio: 928 imagens que retratam áreas afetadas por incêndios florestais.
- Sem Incêndio: 904 imagens de áreas florestais intactas, sem sinais de incêndios.



Fig. 1. Dataset Forest Fire BigData.

As imagens estão no formato JPEG, com resolução de 250x250 pixels, facilitando sua integração em modelos pré-

treinados. O equilíbrio entre as classes no dataset é próximo, o que contribuiu para a criação de modelos que não sejam enviesados em relação a uma das categorias.

Este dataset é especialmente relevante para tarefas de detecção de incêndios, pois inclui imagens diversificadas que representam diferentes condições ambientais, níveis de iluminação e tipos de vegetação. Essa diversidade permite o treinamento de modelos robustos, capazes de generalizar para cenários reais.

Antes de alimentar os modelos, as imagens foram divididas em três subconjuntos: 60 % em Treino, 20% em Validação e 20% em Teste.

C. Treinamento

Os modelos foram treinados para distinguir entre duas classes (com incêndio e sem incêndio), utilizando o mesmo pipeline para cada arquitetura, garantindo consistência na avaliação.

O treinamento dos modelos ResNet18, ResNet50 e EfficientNet foi realizado utilizando o framework **PyTorch**, uma das bibliotecas mais populares para aprendizado profundo. O processo foi conduzido em uma **GPU NVIDIA** disponibilizada pelo Google Colab, que oferece suporte para aceleração de hardware, garantindo tempos de execução reduzidos e melhor manejo de grandes volumes de dados.

Os hiperparâmetros foram definidos de forma criteriosa para garantir um treinamento eficiente. O tamanho do batch foi configurado para 64, proporcionando um equilíbrio entre a capacidade computacional e a estabilidade do treinamento. A taxa de aprendizado inicial foi estabelecida como 0.0001, permitindo que os pesos dos modelos fossem ajustados de forma gradual e estável. O momentum foi definido em 0.9, contribuindo para acelerar a convergência ao considerar gradientes históricos. O número total de épocas foi fixado em 50, garantindo tempo suficiente para que os modelos aprendessem as características do conjunto de dados. Além disso, o step size foi mantido como 10, ajustando dinamicamente a taxa de aprendizado para promover uma convergência mais estável ao longo do treinamento.

O algoritmo de otimização utilizado foi o **SGD** (Stochastic Gradient Descent), amplamente reconhecido por sua eficiência em aprendizado profundo. Essa técnica foi combinada com as configurações de momentum e step size para garantir um treinamento estável e eficiente, especialmente em arquiteturas profundas como ResNet e EfficientNet.

D. Data Augmentation

Para aumentar a diversidade do conjunto de treinamento e melhorar a capacidade dos modelos de generalizar para novos dados, foi utilizada a técnica de data augmentation através das ferramentas nativas do PyTorch. Essa abordagem permite realizar transformações dinâmicas e estocásticas nas imagens durante o treinamento, garantindo que cada batch de dados apresente variações únicas.

As seguintes transformações foram aplicadas ao conjunto de treinamento:

- Inversão horizontal aleatória: As imagens foram invertidas horizontalmente com uma probabilidade de 50% por cento, adicionando invariância em relação à orientação das cenas.
- Rotação aleatória: As imagens foram giradas aleatoriamente, simulando diferentes ângulos de captura.
- Ajustes de cor: Pequenas variações na luminosidade, contraste, saturação e tonalidade foram aplicadas para reproduzir condições de iluminação variáveis em ambientes reais.
- Desfoque gaussiano: Um desfoque foi aplicado utilizando um kernel de tamanho 3, replicando possíveis imperfeições ou ruídos das câmeras de captura.
- Corte e redimensionamento aleatórios: Por meio dessa transformação, foram geradas variações espaciais, garantindo que os modelos aprendessem a identificar regiões relevantes em diferentes tamanhos e perspectivas.
- Normalização: As imagens foram normalizadas utilizando os valores médios e desvios padrão do ImageNet ([0.485, 0.456, 0.406] e [0.229, 0.224, 0.225], respectivamente), compatíveis com os modelos pré-treinados empregados.

Para as etapas de validação e teste, foram aplicadas transformações mais controladas:

- Na validação, foi utilizado o Corte e redimensionamento aleatórios, seguido de normalização, para avaliar os modelos em condições semelhantes às do treinamento.
- No teste, foi ajustado para focar no centro das imagens, assegurando uma avaliação consistente e robusta.

Todas as transformações foram integradas ao pipeline de pré-processamento, permitindo um melhor processamento escalável durante o treinamento e a avaliação.

IV. RESULTADOS E DISCUSSÃO

O treinamento realizado ao longo de 50 épocas resultou em uma avaliação robusta no conjunto de teste do dataset. Além da acurácia, métricas como precision, recall, f1-score e support foram utilizadas para fornecer uma análise detalhada do desempenho de cada modelo. Os resultados indicam que todos os modelos apresentaram um desempenho consistente e satisfatório.

A. Resnet18

A ResNet18 demonstrou um desempenho excepcional, alcançando uma acurácia de 97,82% no conjunto de teste. Este resultado destaca a eficiência das conexões residuais, mesmo em uma arquitetura relativamente leve, ao permitir o aprendizado de características complexas sem degradar o desempenho devido ao aumento de camadas.

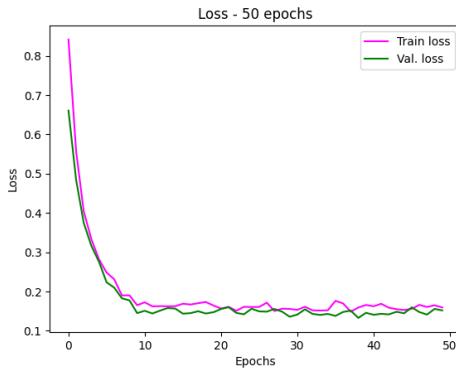


Fig. 2. Gráfico de perdas por época durante o treinamento do modelo ResNet18.

Esse modelo se mostrou particularmente adequado para cenários onde o balanceamento entre eficiência computacional e precisão é necessário.

TABLE I
MATRIZ DE CONFUSÃO: RESNET18

	Pred.: Fire Images	Pred.: Non-Fire Images
Real: Fire Images	182	4
Real: Non-Fire Im.	4	177

TABLE II
RELATÓRIO DE CLASSIFICAÇÃO: RESNET18

Class	Precision	Recall	F1-Score	Support
Fire Images	0.9785	0.9785	0.9785	186
Non-Fire Images	0.9779	0.9779	0.9779	181

B. Resnet50

A ResNet50 obteve uma acurácia ótima também entre os modelos avaliados, alcançando 93,46% no conjunto de teste. Esse desempenho pode ser atribuído à maior profundidade do modelo, que permite a extração de características mais detalhadas e precisas nas imagens.

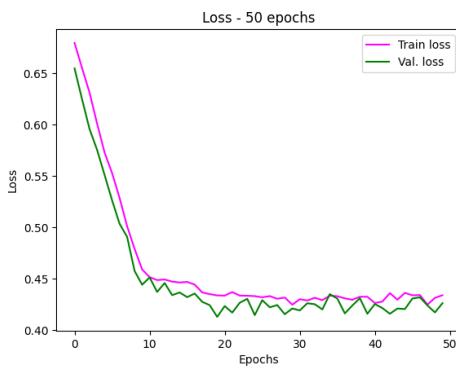


Fig. 3. Gráfico de perdas por época durante o treinamento do modelo ResNet50.

Embora mais complexa, a ResNet50 demonstrou ser uma escolha ideal para tarefas que exigem alta precisão, mesmo ao custo de maior demanda computacional.

TABLE III
MATRIZ DE CONFUSÃO: RESNET50

	Pred.: Fire Images	Pred.: Non-Fire Images
Real: Fire Images	165	21
Real: Non-Fire Im.	3	178

TABLE IV
RELATÓRIO DE CLASSIFICAÇÃO: RESNET50

Class	Precision	Recall	F1-Score	Support
Fire Images	0.9821	0.8871	0.9322	186
Non-Fire Images	0.8945	0.9834	0.9368	181

C. EfficientNet

O EfficientNet, projetado para otimizar o uso de recursos computacionais, alcançou uma acurácia de 89,92% no conjunto de teste. Embora tenha apresentado um desempenho ligeiramente inferior em comparação com as ResNets, o modelo manteve-se competitivo, especialmente em cenários onde a eficiência é uma prioridade.

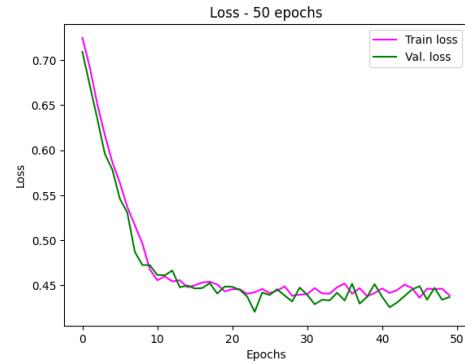


Fig. 4. Gráfico de perdas por época durante o treinamento do modelo EfficientNet.

Sua capacidade de escalabilidade torna o EfficientNet uma opção promissora para aplicações em dispositivos com recursos limitados.

TABLE V
MATRIZ DE CONFUSÃO: EFFICIENTNET

	Pred.: Fire Images	Pred.: Non-Fire Images
Real: Fire Images	171	15
Real: Non-Fire Im.	22	159

TABLE VI
RELATÓRIO DE CLASSIFICAÇÃO: EFFICIENTNET

Class	Precision	Recall	F1-Score	Support
Fire Images	0.8860	0.9194	0.9024	186
Non-Fire Images	0.9138	0.8785	0.8958	181

V. CONCLUSÃO

Neste estudo, exploramos o uso de aprendizado profundo para a detecção de incêndios florestais, utilizando três modelos pré-treinados amplamente reconhecidos: ResNet18, ResNet50 e EfficientNet. Os resultados obtidos destacam o potencial dessas arquiteturas para identificar áreas afetadas por incêndios, contribuindo para estratégias mais eficazes de mitigação e resposta a desastres.

Entre os modelos avaliados, a ResNet18 apresentou o melhor desempenho, com uma acurácia de 97,82%, demonstrando que mesmo arquiteturas mais leves podem alcançar resultados robustos quando combinadas com técnicas como transferência de aprendizado e data augmentation. A ResNet50, embora tenha alcançado uma acurácia ligeiramente inferior de 93,46%, destaca-se por sua capacidade de capturar características mais detalhadas devido à sua maior profundidade. O EfficientNet, com uma acurácia de 89,92%, mostrou-se uma solução eficiente para cenários onde recursos computacionais são limitados.

O uso de métricas complementares, como precision, recall, f1-score e support, reforçou a robustez dos modelos, validando sua capacidade de generalização para diferentes cenários e condições ambientais. As técnicas de data augmentation desempenharam um papel essencial ao aumentar a diversidade do conjunto de treinamento.

Este trabalho demonstra que o aprendizado profundo é uma ferramenta poderosa para a detecção de incêndios florestais, oferecendo uma alternativa automatizada e precisa aos métodos tradicionais. No entanto, desafios como a necessidade de dados mais amplos e diversificados, além da adaptação a diferentes regiões, permanecem e devem ser abordados em trabalhos futuros.

Acreditamos que o avanço contínuo na aplicação de aprendizado profundo trará soluções ainda mais eficazes para o monitoramento e combate aos incêndios florestais, promovendo uma gestão ambiental mais sustentável e segura.

REFERENCES

- [1] Y. Zhao, J. Ma, X. Li, and J. Zhang, "Saliency detection and deep learning-based wildfire identification in UAV imagery," *Sensors*, vol. 18, no. 3, 2018.
- [2] R. Ghali, M. A. Akhloufi, and W. S. Mseddi, "Deep learning and transformer approaches for UAV-based wildfire detection and segmentation," *Sensors*, vol. 22, no. 5, 2022.
- [3] A. Bouguettaya et al., "A review on early wildfire detection from unmanned aerial vehicles using deep learning-based computer vision algorithms," *ScienceDirect*, 2022.
- [4] A. S. Mahdi and S. A. Mahmood, "Analysis of Deep Learning Methods for Early Wildfire Detection Systems," 2022.
- [5] K. Govil et al., "Preliminary results from a wildfire detection system using deep learning on remote camera images," *Remote Sensing*, vol. 12, no. 1, 2020.
- [6] L. Wang et al., "A deep learning-based experiment on forest wildfire detection in machine vision course," 2023.
- [7] H. P. Gupta and R. Mishra, "Utilizing transfer learning and pre-trained models for effective forest fire detection: A case study of Uttarakhand," *arXiv*, 2024.
- [8] Z. Hong et al., "Wildfire detection via transfer learning: a survey," Springer, 2024.
- [9] K. Ahmad et al., "FireXNet: an explainable AI-based tailored deep learning model for wildfire detection on resource-constrained devices," SpringerOpen, vol. 2, 2023.
- [10] S. Partheepan and F. Sanati, "An Analysis of Pre-trained Models Versus Custom Deep Learning Models for Forest Fire Detection," *IEEE Explore*, 2023.
- [11] R. Ghali and M. A. Akhloufi, "Deep learning approaches for wildland fires remote sensing: Classification, detection, and segmentation," *Remote Sensing*, vol. 15, no. 7, 2023.
- [12] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [13] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," *Proceedings of the International Conference on Machine Learning (ICML)*, 2019, pp. 6105–6114.
- [14] Kaggle, "Forest Fire BigData Dataset," 2022.